

Univerzita Karlova v Praze
Matematicko-fyzikální fakulta

DIPLOMOVÁ PRÁCA



Jozef Sabo

Odstránenie rozmazania pomocou dvoch snímok s rôznou dĺžkou expozície

Katedra softwarového inženýrství

Vedúci diplomovej práce: Filip Šroubek, PhD., KSI
Študijný program: Softwarové inženýrství, počítačová grafika

2008

Autor ďakuje vedúcemu diplomovej práce, PhD. Filipovi Šroubkovi, za jeho trpezlivosť, ochotu, poskytnuté materiály a cenné rady pri vedení tejto diplomovej práce.

Prehlasujem, že som svoju diplomovú prácu napísal samostatne a výhradne s použitím citovaných prameňov. Súhlasím so zapožičiavaním práce a jej zverejňovaním.

V Prahe, dňa 8.8.2008

Jozef Sabo

Názov práce	Odstránenie rozmazania pomocou dvoch snímok s rôznou dĺžkou expozície
Autor	Jozef Sabo
Katedra (ústav)	Katedra softwarového inžénýrství
Vedúci diplomovej práce	Filip Šroubek, PhD., UTIA
E-mail vedúceho	sroubekf@utia.cas.cz
Kľúčové slová	Odstránenie rozmazania, dekonvolúcia, adaptívna transformácia farieb

Abstrakt: V predloženej práci študujeme metódy odstránenia rozmazania pomocou dvoch snímok tej istej predlohy s rôznou dobou expozície, pričom sa sústreďujeme na dve hlavné kategórie týchto metód, tzv. farebno-transformačné a dekonvolučné. U oboch kategórií rozoberieme ich teoretické základy a skúmame ich výhody a obmedzenia. Samostatnú kapitolu venujeme vyhodnoteniu a porovnaniu oboch metód na testovacích dátach (obrázky), k testovaniu používame program napísaný v jazyku MATLAB a priložený na samostatnom CD.

Title	Image deblurring using two images with different exposure times
Author	Jozef Sabo
Department	Department of software engineering
Supervisor	Filip Šroubek, PhD., UTIA
Supervisor's email	sroubekf@utia.cas.cz
Keywords	Image deblurring, deconvolution, adaptive color transform

Abstract: In the presented work we study the methods of image deblurring using two images of the same scene with different exposure times, focusing on two main approach categories, a so called color transform and deconvolution methods. We present theoretical backgrounds on both categories and evaluate their limitations and advantages. We dedicate one chapter to compare both methods on test data (images) for which we use a MATLAB program written for this purpose and included in this paper.

1 Obsah

1	Obsah.....	5
2	Úvod.....	6
2.1	Model.....	7
2.2	Dôležité konštrukcie a pojmy	8
2.2.1	Farebný priestor $L^*a^*b^*$	8
2.2.2	Point-spread funkcia	8
3	Metódy transformácie farieb	9
3.1	Ekvalizácia histogramu	9
3.2	Adaptívna transformácia farieb.....	9
3.2.1	Algoritmus.....	9
3.2.2	Algoritmus na vyhľadanie parametrov α a β	10
3.2.3	Výpočtová zložitosť	10
3.2.4	Efektivita.....	10
3.2.5	Experimentálne výsledky z literatúry.....	11
4	Adaptívna transformácia farieb s využitím priestorovej informácie	12
5	Dekonvolučné metódy	13
5.1	Slepá dekonvolúcia.....	13
5.2	Metóda Tico-Vehviainen	13
5.2.1	Odhad point-spread funkcie.....	13
5.2.2	Odstránenie rozmazania.....	13
5.3	Metóda Sun-Yuan	13
6	Prax	14
7	Záver.....	15
8	Použitá literatúra	16

2 Úvod

Technológia reštaurovania obrazu (*image restoration*), predovšetkým odstraňovania rozmazania (*image deblurring*) bola vždy jedným z hlavných predmetov záujmu digitálneho spracovania obrazu. V poslednej dobe, s prudkým rozmachom digitálnej fotografie vďaka neprebernému množstvu dostupných záznamových zariadení (fotoaparáty, mobilné telefóny, digitálne kamery a pod.) jej význam výrazne vzrástol.

Z vlastnej skúsenosti vieme, že získať kvalitný a ostrý snímok nie je vždy jednoduché, najmä pri nevyhovujúcich svetelných podmienkach vyžadujúcich dlhšie expozičné časy. Jednou z najčastejších chýb „chýb krásy“, nielen v amatérskej fotografii, je rozmazanie pohybom (*motion blur*), či už fotografovaného predmetu alebo aparátu; jeho potlačenie, príp. úplné odstránenie je najmä v ručných zariadeniach (*hand-held devices*) veľmi žiaduce.

Podľa (1) je možné metódy odstránenia rozmazania pohybom rozdeliť do zhruba dvoch kategórií, *in-process* a *post-process*¹. Prvá z nich sa sústreďuje na úpravy obrazu, resp. vylepšenie podmienok snímania počas získavania snímku, obvykle hardvérovými metódami (stabilizátory obrazu, príp. CMOS² fotoaparáty). Ich široké nasadenie je však do istej miery obmedzené ich pomerne vysokou cenou. Druhá z nich sa naproti tomu pokúša potlačiť následky rozmazania po expozícii snímku. V prípade, že je k dispozícii iba jeden snímok, je obvyklou voľbou tzv. slepá dekonvolúcia (*blind deconvolution*), ktorá stavia na niekoľkých základných modeloch rozmazania pohybom. V druhej väčšine prípadov však slepá dekonvolúcia nevedie k uspokojivým výsledkom. Tie sú spôsobené nedostatočným odhadom *point-spread funkcie* (PSF, konvolučné jadro rozmazania) vinou vzorkovania a kvantizácie obrazu. V prípade, že máme k dispozícii viac snímok predlohy, napr. viac snímok s rôznym rozmazaním pohybom alebo rôznou kvalitou obrazu, môže dodatočná informácia z nich získaná výsledný obraz podstatne skvalitniť.

V tejto práci sa budeme venovať odstráneniu rozmazania pohybom pomocou dvoch snímok s rôznou dobou expozície, ktorý v jeho základnej podobe navrhli už ----REF ----. Predpokladáme, že prvý snímok je dostatočne exponovaný a tým pádom farebne, jasovo i kontrastne uspokojivý, no zaťažený rozmazaním pohybom, či už fotoaparátu, objektov v scéne, alebo celej scény. Pri druhom snímku je expozičná doba dostatočne malá na to, aby zamedzila prípadnému rozmazaniu, nežiaducim efektom je však nízky jas, skreslenie farieb a menší pomer signálu k šumu (*signal to noise ratio*, SNR).

K riešeniu tohto špecifického problému je možné pristupovať spôsobmi, ktoré taktiež spadajú do dvoch hlavných kategórií. V prvej z nich vôbec neuvažujeme PSF a podexponovaný obraz sa snažíme rekonštruovať na základe jasových a farebných informácií zo správne exponovaného snímku; predpokladáme (s

¹ Anglické názvy boli ponechané kvôli výstižnosti

² Dokážu výrazne skrátiť expozičnú dobu a v rovnakom čase zhotoviť viac snímok, ktoré sú potom podrobené úprave podľa (2)

dostatočne veľkou presnosťou), že rozmazanie pohybom tieto veličiny neovplyvňuje. Obvykle sa jedná o nájdenie transformačnej funkcie medzi farebným a jasovým spektrom (histogramom) jedného a druhého obrázku a jej aplikáciu na podexponovaný obrázok. Existuje niekoľko prístupov, od jednoduchšej adaptívnej ekvalizácie histogramu až po adaptívnu transformáciu farieb s využitím priestorovej informácie (2), ktorá však neuvažuje šum v podexponovanom obrázku. Už na prvý pohľad použiteľnosť týchto metód obmedzuje pomer signálu k šumu v podexponovanom obraze a skreslenie farieb, ktoré je pri nedostatočnom osvetlení obvyklé.

Druhá kategória obsahuje metódy, ktoré sa snažia odstrániť rozmazanie čo najlepším odhadom point-spread funkcie z oboch snímok a následnú dekonvólciu obrazu rozmazaného pohybom. Metódy v tejto skupine poskytujú zvyčajne kvalitatívne podstatne lepšie výsledky, sú však výpočtovo omnoho náročnejšie (odhad PSF), čo môže ich nasadenie v prenosných zariadeniach s menšou výpočtovou kapacitou obmedziť.

Cieľom tejto práce je rozobrať existujúce metódy a na základe generovaných a skutočných testovacích dát porovnať ich (ne)vhodnosť pre konkrétne situácie (v zmysle pomeru signálu k šumu, expozičných dôb a pod.). Nekladíme si za cieľ implementovať efektívne algoritmy a taktiež nie je našim cieľom poskytnúť podrobný rozpis všetkých existujúcich prístupov. Pre zjednodušenie situácie nebudeme riešiť spôsob získania dvoch obrázkov tej istej predlohy s rôznou dĺžkou expozície, ako je tomu napr. v (1). Sústreďme sa na šedotónové obrázky a kde to bude potrebné, zmienime aj rozšírenie do farby.

2.1 Model

Pre sprehľadnenie výkladu uvedieme najprv matematický model situácie, s ktorým budeme v celom ďalšom výklade pracovať, pokiaľ nebude uvedené inak.

Nech $H(x)$ je obrazová funkcia pôvodného, nedegradovaného šedotónového obrazu s rozmermi $M \times N$. Označme $F(x)$ obrazovú funkciu obrazu, ktorý vznikol z $H(x)$ rozmazaním pohybom a v malej miere zašumením³. $G(x)$ nech je obrazová funkcia obrazu podexponovaného a zašumeného. Podľa (3) môžeme písať :

$$\begin{aligned} F(x) &= H(x) * P(x) + n_1(x) \\ G(x) &= \alpha H(x) + n_2(x) \end{aligned} \quad [1]$$

kde $x = (x, y)$ sú súradnice obrazového bodu, $P(x)$ je vyjadrenie point-spread funkcie popisujúcej rozmazanie pohybom, α je zmena jasu v dôsledku kratšej expozície (zjavne $\alpha \leq 1$) a n_1 a n_2 predstavujú šum. Uvažujeme aditívny gaussovský šum s $\mu_1 = \mu_2 = 0$ a $\sigma_1^2 \ll \sigma_2^2$. Amplitúda šumu je v prvom prípade podstatne nižšia v dôsledku dlhšej expozície a teda vyššieho SNR. Rozšírenie na farebné obrazy v tomto prípade nezmení tvar vzťahu [3].

³ Šum je do istej miery prítomný v každom, i najdokonalejšom zobrazovacom zariadení

2.2 Dôležité konštrukcie a pojmy

2.2.1 Farebný priestor $L^*a^*b^*$

V ďalšom výklade, predovšetkým pri implementácii a vyhodnocovaní kvality algoritmov odstránenia rozmazania sa budeme často stretávať s reprezentáciou farieb v priestore $L^*a^*b^*$ ⁴.

Farebný priestor $L^*a^*b^*$ vzišiel z farebného priestoru XYZ (presnejšie *CIE 1931 XYZ*) ktorý je jedným z prvých matematicky definovaných farebných priestorov. Priestor XYZ je založený na vnímaní svetla ľudským okom a odráža fakt, že vnímanie farieb v ľudskom oku zabezpečujú tri druhy čapíkov, konkrétne pre dlhé (L), stredné (M) a krátke (S)⁵ vlnové dĺžky viditeľného svetla. V princípe je teda farebný vnem popísateľný trojicou hodnôt. V modeli XYZ je farebný vnem reprezentovaný troma hodnotami X, Y a Z, ktoré zhruba odpovedajú červenej, zelenej a modrej farbe. Pre účel tejto práce nie je potrebné zachádzať do ďalších detailov, tie je možné nájsť napr. v [4].

Farebný model $L^*a^*b^*$ je subtraktívny, t.j. slúži na reprezentáciu farieb materiálov a povrchov, podobne ako model *CMYK* alebo *HSV* a je postavený na doplnkových farbách. Naproti tomu model *RGB* je aditívny, t.j. reprezentuje farby svetelných zdrojov.

Farba je v modeli $L^*a^*b^*$ popísaná ako trojica hodnôt L^* , a^* a b^* , kde L^* vyjadruje svetlosť v rozsahu 0 (čierna) do 100 (biela) a súradnice a^* a b^* reprezentujú rozsahy zelená ($-a$) až červená ($+a$) a modrá ($-b$) až žltá ($+b$). V porovnaní s priestorom *CIE 1931 XYZ* odpovedá popis a rozloženie farieb v priestore $L^*a^*b^*$ lepšie vnímaniu farieb ľudským zrakom. Inou a veľmi podstatnou výhodou tohto priestoru je, že jednotlivé zložky môžeme upravovať individuálne, napr. zmeniť farebný tón obrazu reprezentovaného v modeli $L^*a^*b^*$ bez toho, aby sme ovplyvnili jeho jas.

Prevod z farebného priestoru *RGB* do priestoru $L^*a^*b^*$ nie je jednoduchý a existuje zhruba 5 modelov s rôznym stupňom presnosti. Sústredíme sa na najjednoduchší z nich, lineárny, vyjadrený maticovým súčinom

[2]

ktorý pre naše účely bohato postačuje. Spätný prevod vykonáme násobením inverznou maticou:

[3]

2.2.2 Point-spread funkcia

Pojem point-spread funkcia označuje konvolučné jadro rozmazania obrazu v modeli popísanom vzťahom [1].

⁴ Priestor L, a, b definoval už Hunter v r. 1948, označenie Lab (prípadne $L^*a^*b^*$) sa však v súčasnosti obvykle používa ako neformálna skratka farebného priestoru CIE 1976 (L^* , a^* , b^*)

⁵ Z anglického L-long, M-middle a S-short

3 Metódy transformácie farieb

3.1 Ekvalizácia histogramu

3.2 Adaptívna transformácia farieb

3.2.1 Algoritmus

Metóda adaptívnej transformácie farieb, podrobne popísaná v (5) je jednoduchou a v závislosti od vstupov efektívnou metódou na odstránenie rozmazania pomocou dvoch snímok rovnakej predlohy. Pre svoju výpočtovú nenáročnosť sa hodí do zariadení, ktorých výkonnostné možnosti sú obmedzené (predovšetkým fotoaparáty v mobilných telefónoch).

Základnou ideou (a súčasne hlavnou výzvou) adaptívnej transformácie farieb je úprava tmavšieho, podexponovaného obrazu spôsobom, ktorý využije charakteristiku správne exponovaného, ale rozmazaného obrazu. Samozrejme, úpravu podexponovaného obrazu môžeme dosiahnuť i obvyklou tonálnou korekciou (ktorá je bežnou súčasťou mnohých zariadení). Dodatočná informácia získaná z rozmazaného obrázku výsledok, ako uvidíme nižšie, podstatne skvalitňuje.

Vstupom algoritmu adaptívnej transformácie je podexponovaný obrázok a jeho vzhľad sa upravuje využitím **strednej hodnoty (jas) a rozptylu (kontrast)** rozmazaného obrazu adaptívnym spôsobom. Hlavným prínosom tejto metódy je automatizácia procesu, ktorým sa tonálna korekcia vykonáva. Obr. X ukazuje typickú krivku tonálnej korekcie, ktorou sa hodnoty R, G a B podexponovaného obrazu mapujú na výstupné hodnoty. V princípe krivka farebnej korekcie posúva histogram presunom strednej hodnoty bližšie k jasnej časti histogramu.

Funkcia

$$f(x) = \frac{\log(\alpha x - x + 1)}{\log \alpha} \quad [4]$$

kde x sú hodnoty pixelov vstupného obrazu a α parameter ovplyvňujúci výslednú úroveň jasu je veľmi vhodnou pre účely tonálnej korekcie, pretože jej použitie nespôsobuje **nasýtenie intenzity** vo výstupnom obraze a výsledná intenzita je ľahko upraviteľná jediným parametrom. Optimálna hodnota α bude taká, pri ktorej bude jas (stredná hodnota) výstupného a rozmazaného obrazu zhodná.

Predchádzajúca úprava zlepšuje i kontrast obrazu. Pre ďalšie zlepšenie kontrastu môžeme uvažovať nasledujúcu funkciu

$$g(x) = \frac{\tan^{-1}(\beta(f(x) - 0.5)) + 0.5}{2 \tan(\beta/2)} \quad [5]$$

ktorou dáme do rovnosti kontrast rozmazaného a vstupného obrazu. Táto funkcia má spomedzi mnohých ďalších (*tangentové hyperbolické, nepárne exponenciálne, kosínusové, logaritmické a arcus-tangensové apod.*) výhodu jediného parametra a taktiež nespôsobuje nasýtenie intenzít (mapovanie širšej oblasti spektra – histogramu na užšiu). Pre nájdenie hodnôt α a β optimálnym spôsobom použijeme princíp binárneho vyhľadávania z (6).

3.2.2 Algoritmus na vyhľadanie parametrov α a β

3.2.3 Výpočtová zložitosť

3.2.4 Efektivita

3.2.4.1 Skreslenie farieb

Skreslenie farieb (*color distortion*) sa obvykle meria CIELAB farebným rozdielom ΔE daným vzťahom, ktorý je euklidovskou vzdialenosťou pôvodného obrazu od jeho skresleného variantu v priestore $L^*a^*b^*$:

$$\Delta E = \frac{1}{MN} \sum_{i=1}^M \sum_{j=1}^N \Delta C_{ij} \quad [6]$$

$$\Delta C_{ij} = \sqrt{\Delta L_{ij}^{*2} + \Delta a_{ij}^{*2} + \Delta b_{ij}^{*2}}$$

kde ΔL^* , Δa^* a Δb^* sú rozdiely farebných zložiek v priestore $L^*a^*b^*$. Ako je uvedené v (5), podľa vnímania skreslenia ľudským okom je možné hodnoty skreslenia rozdeliť nasledovne.

Tab. 1. Vnímanie skreslenia ľudským okom

$\Delta E < 3$	<i>Takmer nepostrehnuteľné</i>
$3 < \Delta E < 6$	<i>Viditeľné, prijateľné</i>
$\Delta E > 6$	<i>Neprijateľné</i>

3.2.4.2 Šum

Typické SNR u obrázkov zachytených digitálnymi fotoaparátmi sa pohybuje od 10dB do 40dB v závislosti na nastavení citlivosti ISO (*ISO setting*)(5). V tejto metóde predpokladáme nastavenie rovnakej citlivosti pri získavaní ostrého i rozmazaného obrazu, rozdielna je iba expozičná doba.

Ako je uvedené v (5), aplikácia adaptívnej transformácie farieb na podexponovaný obrázok zmení strednú hodnotu šumu nasledovne:

$$\sigma_{výst.}^2 = \int [f(x) * g(x)]^2 p(x) dx \quad [7]$$

kde $p(x)$ označuje obrazovú funkciu podexponovaného obrazu vrátane šumu. Keďže $f(x)$ a $g(x)$ sú nelineárne funkcie, tento vzťah nemá analytické riešenie. Vo väčšine prípadov nie je použitie funkcie $g(x)$ nutné. Teda, pokiaľ berieme iba funkciu $f(x)$, na malých intervaloch ju môžeme považovať za lineárnu. Nasledujúci vzťah udáva sklon dotyčnice k $f(x)$ na malom okolí bodu x_1 :

$$a = \left. \frac{df(x)}{dx} \right|_{x=x_1} = \frac{\log \alpha}{x_1 + \frac{1}{\alpha-1}} \quad [8]$$

pre $f(x) = ax + b$, z čoho plynie pre rozptyl vo výstupnom obraze vzťah

$$\sigma_{výst.}^2 = a^2 \sigma_{vstup}^2 \quad [9]$$

Keďže rovnaký vzťah platí pre rozptyl celého obrazu, vidíme, že v praxi hrá skreslenie farieb väčšiu úlohu ako šum.

3.2.5 Experimentálne výsledky z literatúry

V (5) sú uvedené výsledky štúdie, ktorá bola vykonaná na 240 obrázkoch z 12 rozdielnych scén. Ako sa ukazuje, aplikácia ATF na obrázky s úrovňou expozície zníženou o 20% neprodukuje postrehnutelné skreslenie. Zníženie o 70% produkuje skreslenie v prijateľnej úrovni, aplikácia parametra α pre $\alpha > 10$ vyústila v neprijateľné farebné skreslenie. Praktické výsledky v zmysle tejto práce sú uvedené v kapitole 6.

4 Adaptívna transformácia farieb s využitím priestorovej informácie

5 Dekonvolučné metódy

5.1 Slepá dekonvolúcia

5.2 Metóda Tico-Vehviainen

5.2.1 Odhad point-spread funkcie

5.2.2 Odstránenie rozmazania

5.3 Metóda Sun-Yuan

6 Prax

7 Záver

Ako sa ukazuje,

8 Použitá literatura

1. **Jia J., Sun J., Tang C.K., Shum H.Y.** *Bayesian correction of image intensity with spatial consideration.* : Computer Science Department, Hong Kong University of Science and Technology, 2007.
2. **Liu X., Gamal A.** *Simultaneous image formation and motion blur restoration via multiple capture.* : Proc. Int. Conf. Acoustics, Speech, Signal Processing, 2001.
3. **Tico M., Vehvilainen M.** *Estimation of motion blur point spread function from differently exposed images.* s.l. : Nokia Research Center, Tampere, Finland, 2006.
4. **Beneš B., Felkel P., Sochor J., Žára J.** *Moderní počítačová grafika, 2. vydání.* s.l. : Computer Press, 2004.
5. **Razligh Q.R., Kehtarnavaz N.** *Image blur reduction for cell-phone cameras via adaptive tonal correction.* s.l. : Department of Electrical Engineering, University of Texas at Dallas, 2007.
6. **Biedl T., Chan T., Demaine E., Fleischer R., Golin M., King J., IanMun J.** *Fun Sort - or the Chaos of Unordered Binary Search.* s.l. : Discreate Applied Mathematics, vol. 144, p. 231-236, 2004.
7. **Yuan L., Sun J., Quan L., Shum H.Y.** *Image Deblurring with blurred/noisy image pairs.* s.l. : Computer Science Department, Hong Kong University of Science and Technology, 2007.
8. **Tico M., Vehvilainen M.** *Image stabilization based on fusing the visual information in differently exposed images.* s.l. : Nokia Research Center, Tampere, Finland, 2007.